Chapter 10. Classic Games

1. Introduction

1-1. Why Classic Games ?
1-2. AI and RL in Games : State of the Art

2. Game Theory

2-1. Nash Equilibrium
2-1-1. Definition
2-1-2. Three Conditions for Unique NE

2-2. Game Tree Search (Minimax Search)
2-2-1. Minimax Value Function
2-2-2. Minimax Search

2-3. Self-Play Reinforcement Learning

3. Combining Reinforcement Learning and Minimax Search

3-1. Introduction
3-2. TD Root
3-3. TD Leaf
3-4. TreeStrap
3-5. Simulation-Based Search

4. Reinforcement Learning in Imperfect-Information Games

4-1. Smooth UCT Search

5. Conclusion

1. Introduction

1-1. Why Classic Games ?

#. 강화학습의 연구는 Classic Game를 이용하여 이루어진다. 왜냐하면 classic game의 특징과 관련되어 있는데, 첫 번째로 바둑과 같이 규칙은 간단하지만 깊은 개념이 들어있기 때문이다. 두 번째로 오랫동안 사람들이 play하면서 수많은 경험과 지식이 쌓여있기 때문이다. 세 번째로 classic games는 AI의 초파리와 같은 존재이다. 즉 실험하는데 많이 사용한다는 것이다. 마지막으로는 현실 세계의 상황들을 반영하는 소우주와 같기 때문이다.

1-2. AI and RL in Games : State of the Art

#. 아래와 같이 일반적인 AI, RL에서 State of the Art를 정리할 수 있다.

AI in Games : State of the Art

Program	Level of Play	Program to Achieve Level
Checkers	Perfect	*Chinook*
Chess	Superhuman	*Deep Blue*
Othello	Superhuman	*Logistello*
Backgammon	Superhuman	*TD-Gammon*
Scrabble	Superhuman	*Maven*
Go	Grandmaster	*MoGo*[1], *Crazy Stone*[2], *Zen*[3]
Poker[4]	Superhuman	*Polaris*

RL in Games : State of the Art

Program	Level of Play	RL Program to Achieve Level
Checkers	Perfect	*Chinook*
Chess	International Master	*KnightCap / Meep*
Othello	Superhuman	*Logistello*
Backgammon	Superhuman	*TD-Gammon*
Scrabble	Superhuman	*Maven*
Go	Grandmaster	*MoGo*[1], *Crazy Stone*[2], *Zen*[3]
Poker[4]	Superhuman	*SmooCT*

a. 'Perfect'는 완전히 풀렸다는 의미이고, 'Superhuman'은 사람 1등을 이겼다는 것이다. 'Grandmaster'는 사람 수준에서의 pro-level이다.

#. 다수의 참여자가 어떤 규칙 하에서 reward를 최대화하는 각각의 policy(optimality)를 구하기 위해 게임이론을 도입한다. 그리고 이 균형을 찾기 위한 방법론으로 Game Tree Search와 Self-Play RL가 있다.

2-1. Nash Equilibrium

2-1-1. Definition

#. i명의 참여자가 있을 때, 나를 제외한 다른 참여자들의 policy가 고정되어 있다고 가정했을 때, 나의 optimal policy는 $\pi_*^i(\pi^{-i})$로 정의되며 이를 Best response라고 한다. Nash Equilibrium은 i명의 참여자 모두 Best response인 경우를 의미하며 아래와 같이 정의한다.

$$\pi^i = \pi_*^i\left(\pi^{-i}\right)$$

a. 이 균형에서는 모두 자신이 생각하는 최선의 전략을 선택하고 있기 때문에, 전략을 바꿀 유인이 없는 것이 특징이다.

b. Single-Agent 문제에서는 하나의 agent를 제외하곤 다른 player를 모두 Env.로 묶을 수 있기 때문에, MDP로 표현할 수 있으며, Best Response가 곧 optimal policy가 된다.

c. 나와 나 자신이 붙으며 학습하는 Self-Play 문제에서 Nash Equilibrium을 찾기 위해서는 Env.가 동적으로 변하는 과정 속에서 fixed-point를 찾는 것이라 할 수 있다. 왜냐하면 b에서와 같이 한 agent 입장에서는 자신을 제외한 모든 것을 Env.로 취급하기 때문에 지속적으로 다른 agent의 policy가 변하면 그 agent 입장에서는 Env.이 변하는 것으로 되기 때문이다.

d. 일반적으로 Nash Equilibrium은 Unique하지 않지만 2-1-2.에서 살펴볼 것과 같이 3가지 조건이 충족되면 Nash Equilibrium은 unique하다.

2-1-2. Three Conditions for Unique Nash Equilibrium

#. 3가지 조건은 아래와 같으며 이 조건들이 만족되면 Nash Equilibrium이 Unique하다.

Two-Player Alternative Game	두 명의 player가 번갈아 가면서 한 번씩 action을 하는 게임이다.
Zero-Sum Game	$R^1+R^2=0$로 표현되며, 한 player의 이득이 다른 player의 손해가 된다.
Perfect Information	상대가 어느 state인지 알 수 있는 것을 의미한다. 예를 들어 Go, Chess, Checker 등의 게임이 있고, Imperfect Information은 상대의 state를 완전히 모르는 것을 의미한다. 예를 들어 Poker가 있다.

2-2. Game Tree Search (Minimax Search)

2-2-1. Minimax Value Function

#. 2-Players(백/흑)의 상황에서 어느 한 player를 기준으로, 현재의 state에서 둘 다 최선의 policy로 play를 하였을 때, 누가 이길 것인지를 나타내는 값이며 minimax value라고도 한다. minimax value function의 parameter를 minimax policy라고 하며 이는 Nash Equilibrium이다. 표기는 아래와 같다.

Joint Policies	$\pi = \langle \pi_1, \pi_2 \rangle$
Value Function	$v(s) = E_\pi[G_t \mid S_t = s]$
Minimax Value Function	$v_*(s) = \underset{\pi_1}{\max}\underset{\pi_2}{\min} v_\pi(s)$

a. 백 입장에서 이기는 것을 1, 흑 입장에서는 –1이 된다. Example에 살펴보겠지만, state의 minimax value 가 양수이면 백이 이긴다는 의미, 0이면 비긴다는 의미, 음수이면 흑이 이긴다는 의미이다.

b. 따라서 Minimax Search에서는 현 state에서 누가 이길지를 나타내는 minimax value function을 찾아내는 것이 목적이다.

c. 각 state마다 unique minimax value function이 존재한다.

2-2-2. Minimax Search

#. 어떤 state의 Minimax Value Function을 찾기 위한 알고리즘이며 아래의 예를 들어 그 과정을 알아보자. 즉 백과 흑 2명의 players가 있으며 각각 action이 2가지며 zero-sum and alternative game이다. 검은 node는 백을 의미한다.

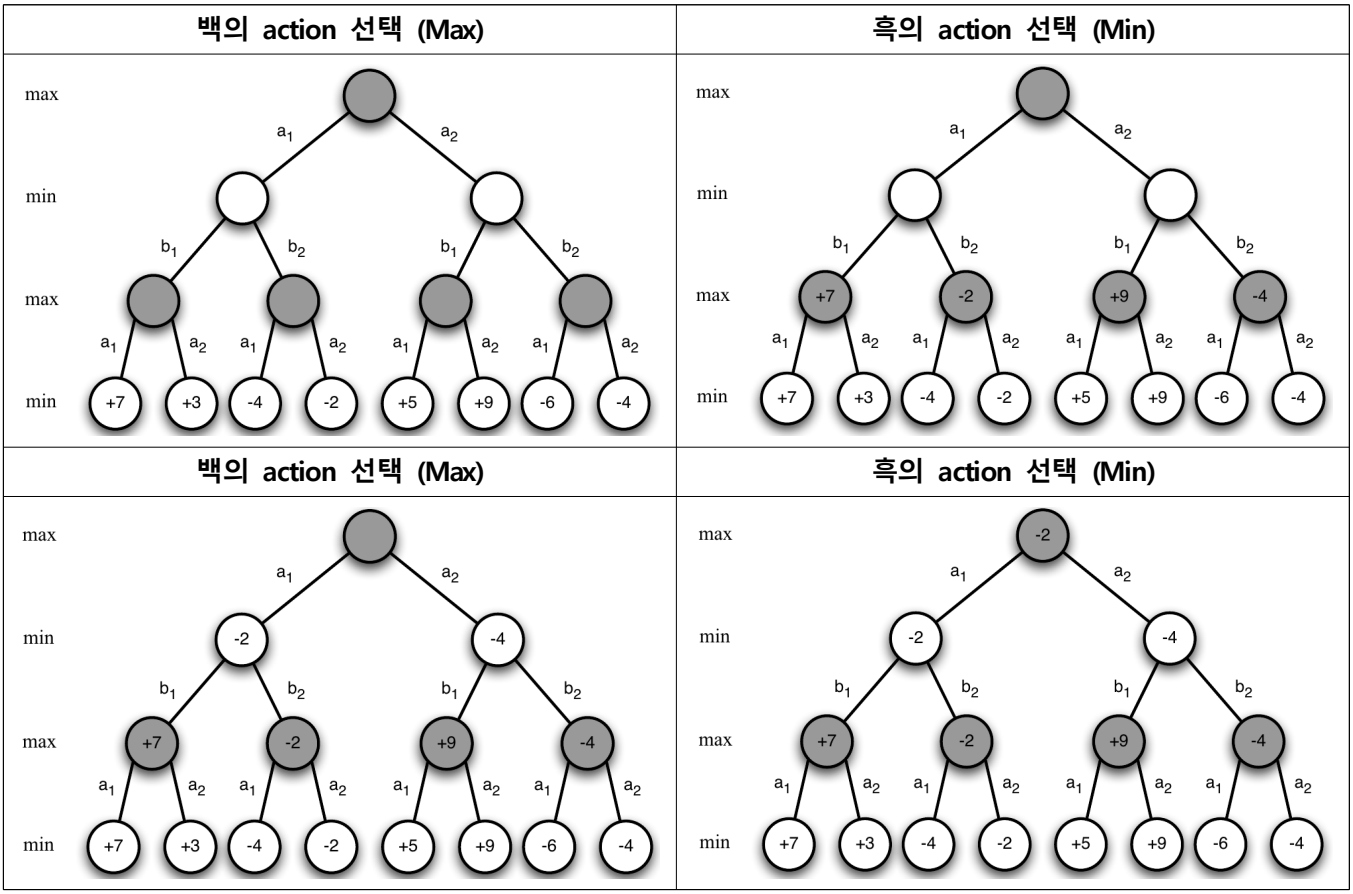

a. 결과를 보면 현재 state의 minimax value function의 값은 –2가 되었으므로 이 state에서는 흑이 무조건 이길 수밖에 없다.

b. 이 알고리즘은 전통적 기계학습이며 자체로도 강력한 성능을 발휘하며, Deep Learning과 결합하면 더 높은 성능을 낼 수 있다.

c. 위의 예시에서 알 수 있듯이 action이 2가지이고 terminal state가 짧더라도 search 해야 하는 경우의 수는 기하급수적으로 증가함을 알 수 있다. 이를 해결하기 위해 value function approximator[1]를 사용하여 fixed depth까지만 search를 진행한 후 fixed depth 해당 state에는 estimated value function 값을 할당하고 현 state의 minimax value를 계산하는 truncate 방법이 있다.

d. 이러한 truncate의 방법론으로는 흥미 없는 tree의 부분을 잘라내는 Alpha-beta Search가 있다.

e. Value Function Approximator의 간단한 예시인 Binary-Linear value function을 알아보면, feature vector 인 $x(s)$을 만들고 weight vector w을 곱해준 후 더해준 것이 해당 state의 estimated value이며, chess를 예로 들면 아래와 같으며 이 때 weight vector는 handcrafted이다.

1) $v(s,w) \approx v_*(s)$

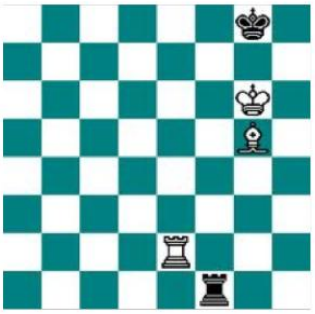

$$v(s,\mathbf{w}) = \mathbf{x}(s)\cdot\mathbf{w} = \begin{bmatrix}1\\1\\0\\1\\0\\0\\\vdots\end{bmatrix}\cdot\begin{bmatrix}+5\\+3\\+1\\-5\\-3\\-1\\\vdots\end{bmatrix}$$

$$v(s,\mathbf{w}) = 5+3-5=3$$

f. 위와 같은 방법론을 사용한 것이 Deep-Blue와 Chinook이다.

Deep-Blue	Chinook
■ Knowledge ■ 8000 handcrafted chess features ■ Binary-linear value function ■ Weights largely hand-tuned by human experts ■ Search ■ High performance parallel alpha-beta search ■ 480 special-purpose VLSI chess processors ■ Searched 200 million positions/second ■ Looked ahead 16-40 ply ■ Results ■ Defeated human champion Garry Kasparov 4-2 (1997) ■ Most watched event in internet history	■ Knowledge ■ Binary-linear value function ■ 21 knowledge-based features (position, mobility, ...) ■ x4 phases of the game ■ Search ■ High performance alpha-beta search ■ Retrograde analysis ■ Search backward from won positions ■ Store all winning positions in lookup tables ■ Plays perfectly from last n checkers ■ Results ■ Defeated Marion Tinsley in world championship 1994 ■ won 2 games but Tinsley withdrew for health reasons ■ Chinook *solved* Checkers in 2007 ■ perfect play against God

2-3. Self-Play Reinforcement Learning

#. Self-Play는 한 player가 두 명의 players 역할을 하는 것을 의미하며, 이러한 방식에서 MC, TD(0), TD(λ)와 같은 value-based RL algorithms를 사용하여 학습하는 것을 의미한다. 하지만 two players game의 상황이므로 value가 minimax value로 바뀌었고[2], intermediate reward가 없어서 r,γ가 사라진 것이 기존 방법과의 차이이다. 아래는 각 algorithm에 따른 학습(update)방식이다.

MC	update minimax value function approximator towards the return G_t $\Delta\mathbf{w} = \alpha(G_t - v(S_t,\mathbf{w}))\nabla_{\mathbf{w}} v(S_t,\mathbf{w})$
TD(0)	update minimax value function approximator towards successor value $v(S_{t+1})$ $\Delta\mathbf{w} = \alpha(v(S_{t+1},\mathbf{w}) - v(S_t,\mathbf{w}))\nabla_{\mathbf{w}} v(S_t,\mathbf{w})$
TD(λ)	update minimax value function approximator towards the λ-return G_t^λ $\Delta\mathbf{w} = \alpha(G_t^\lambda - v(S_t,\mathbf{w}))\nabla_{\mathbf{w}} v(S_t,\mathbf{w})$

2) 따라서 minimax value function approximator를 사용한다.

a. Classic games는 deterministic game이다. 즉 게임 rule에 따라 action을 하면 다음 state가 명확히 정해지는 특징이 있다. 따라서 policy improvement를 할 때, q-value대신 state value만 알아도 충분하다. 왜냐하면 어떤 state의 value만 알면 deterministic 하므로 게임의 rule에 따라 어떤 action을 취하면 되는지 알기 때문이다.

b. 구체적으로 백의 입장에서는 다음 state의 value가 최대가 되는 action을, 흑의 입장에서는 다음 state value가 최소가 되는 action을 선택하면 된다. 이렇게 하면 두 players의 joint policy가 improvement된다. 이를 수식으로 표현하면 아래와 같다.

AfterState	$q_*(s,a) = v_*(succ(s,a))$
Action selection for White	$A_t = \underset{a}{\text{argmax}}\ v_*(succ(S_t,a))$
Action selection for Black	$A_t = \underset{a}{\text{argmin}}\ v_*(succ(S_t,a))$

c. 이를 적용한 예시로 Othello 게임에 적용한 Logistello가 있다. 이는 binary-linear value function을 사용하여 돌들의 position의 조합으로 feature를 만들었다. 이를 바탕으로 policy iteration을 사용하여 학습을 하였는데, 현재 policy로 self-play를 통해 game을 만들고 이로 experiences를 생성한 다음, 이를 바탕으로 MC를 사용[3]하여 현재 policy를 평가한다. 평가를 하고 나면 Greedy policy improvement를 진행하게 된다. 이 때 백은 maximize를 하고 흑은 minimize를 선택하도록 한다.

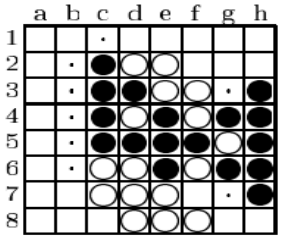

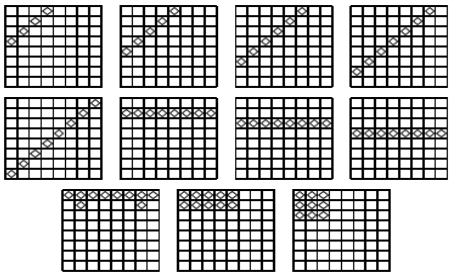

d. 다른 예시로 Neural Net.을 Backgammon을 적용한 TD Gammon이 있다. Neural Net.을 random으로 초기화한 다음 self-play로 진행하면서 아래의 식과 같이 non-linear TD(λ) algorithm으로 policy를 평가하였다. policy improvement는 exploration없이[4] Greedy 방식으로만 진행하였다. 이 방식으로 학습하면 항상 수렴하였다.

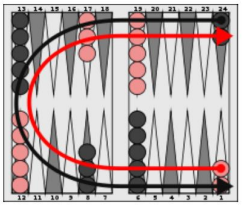

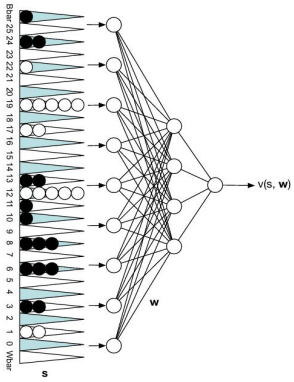

$$\delta_t = v(S_{t+1}, \mathbf{w}) - v(S_t, \mathbf{w})$$
$$\Delta \mathbf{w} = \alpha \delta_t \nabla_{\mathbf{w}} v(S_t, \mathbf{w})$$

3) Outcome을 regression을 한다는 의미이다. 즉 어떤 state에서 이겼으면 1, 졌으면 -1이 되도록 학습하는 것이다.
4) Backgammon game 자체에 inherent stochasticity이 있어서 exploration이 들어있기 때문이다.

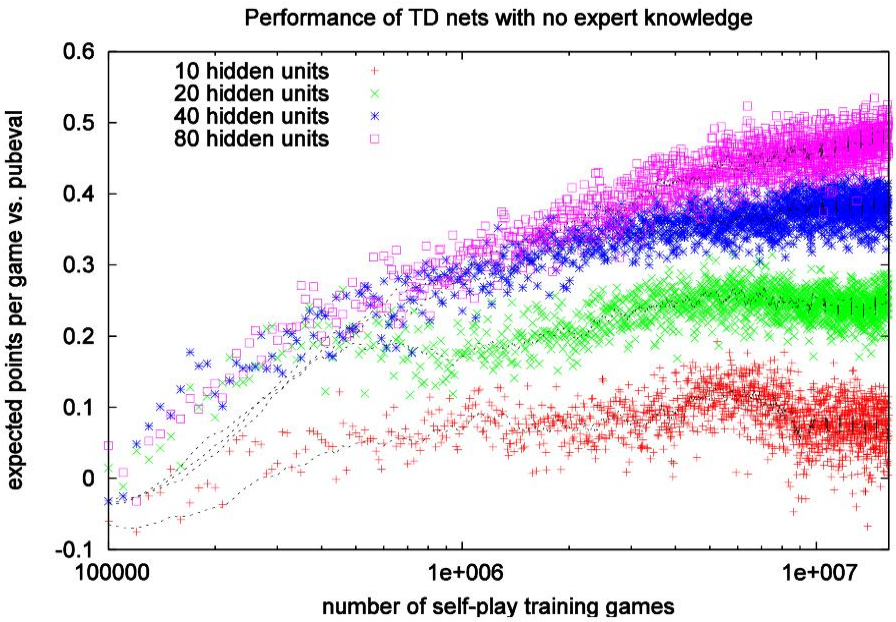
Performance of TD nets with no expert knowledge
10 hidden units
20 hidden units
40 hidden units
80 hidden units
expected points per game vs. pubeval
0.6
0.5
0.4
0.3
0.2
0.1
0
-0.1
100000
1e+006
1e+007
number of self-play training games

3. Combining Reinforcement Learning and Minimax Search

3-1. Introduction

#. 이전까지는 learning과 search가 분리되어 있었다. 즉 TD learning으로 state value를 구한 다음에, ($v(S_t, w) \leftarrow v(S_{t+1}, w)$) 다음에 이를 이용하여 minimax search($v_+(S_t, w) = \min_{s \in \leq} imax_{aves(S_t)} v(S, w)$)를 하였다. 이 방법의 한계는 search의 결과가 learning에 영향을 주지 않는 다는 것이다. 이를 보완하기 위해 search과정을 learning에 포함시켜 더 좋은 state value를 찾는 3가지 방법론(TD-Root, TD-Leaf, Tree Strap)을 배울 것이다.

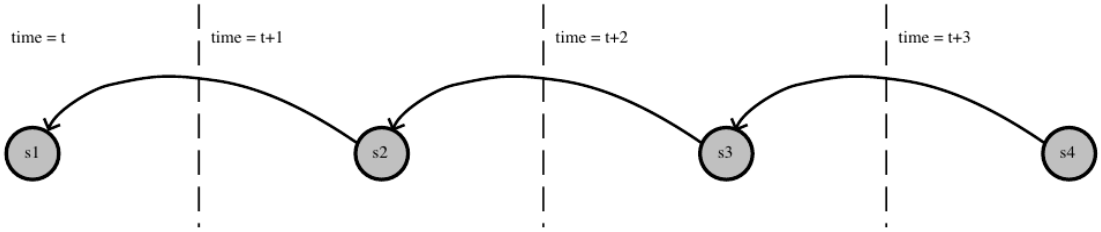

3-2. TD-Root

#. TD-Learning은 $v(S_t)$을 $v(S_{t+1})$을 이용하여 update하는 것이었다. TD-Root는 $v(S_t)$을 update할 때, $v(S_{t+1})$에서 minimax search의 결과를 이용하는 것이 핵심이다. 왜냐하면 한 step 진행 후에서의 search 결과가 더 정확하기 때문에 이 방향으로 $v(S_t)$을 update하는 것은 의미가 있기 때문이다.

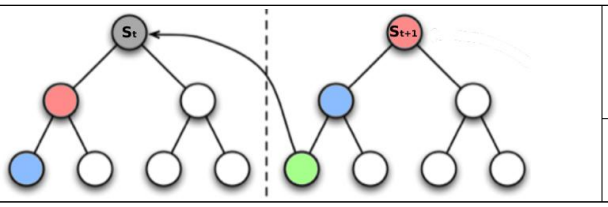

$$v_+(S_t, \mathbf{w}) = \min_{s \in leaves(S_t)} imax\ v(s, \mathbf{w})$$

$$v(S_t, \mathbf{w}) \leftarrow v_+(S_{t+1}, \mathbf{w}) = v(l_+(S_{t+1}), \mathbf{w})$$

a. 위의 notation에서 v_+은 minimax search의 결과 값을 의미하며 l_+은 state s에서 minimax search의 결과로 도달하는 leaf node를 의미한다.

3-3. TD-Leaf

#. TD-Root에선 $v(S_t)$을 update해주었다면, TD-Leaf에선 $v(l_+(S_t), w)$을 update해주는 것이다. 즉 S_{t+1}에서 minimax search한 결과 값을 이용하여 S_t에서 minimax search한 결과 값을 update해주는 것이다.

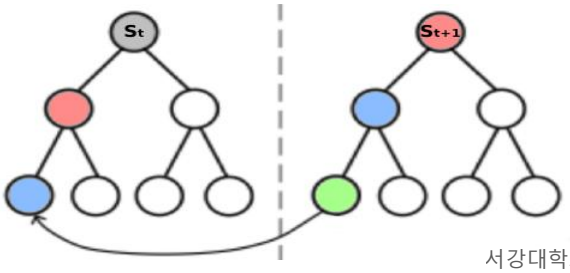

$$v_+(S_t, \mathbf{w}) = \min_{s \in leaves(S_t)} imax\ v(s, \mathbf{w})$$

$$v_+(S_{t+1}, \mathbf{w}) = \min_{s \in leaves(S_{t+1})} imax\ v(s, \mathbf{w})$$

$$v_+(S_t, \mathbf{w}) \leftarrow v_+(S_{t+1}, \mathbf{w})$$

$$\Longrightarrow v(l_+(S_t), \mathbf{w}) \leftarrow v(l_+(S_{t+1}), \mathbf{w})$$

3-4. Tree Strap

#. 특정 state에서의 minimax search를 통해 terminal state에 도달하게 되면 결과 value를 얻게 된다. 이 때, 지나왔던 각각의 node에서 terminal state까지 minimax search한 결과 value로 각각 update를 해주는 방법이다.

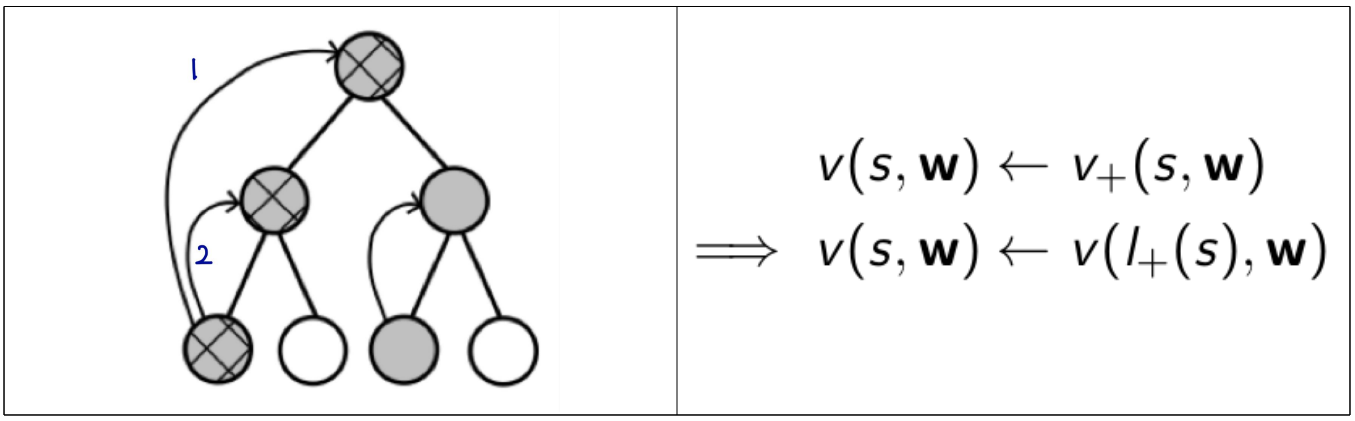

a. TD-Root와 TD-Leaf는 real step과 imaginary step이 섞여있는 상태인데, 차라리 상상 속에서 모든 것을 해버리자는 배경에서 나온 것이다. 즉 real step을 하지 않고 모두 imaginary step(minimax search)로 구성되어 있다.

3-5. Simulation-Based Search

#. 대표적으로 MCTS이다. 이 방법은 Search과정에서 MC control을 사용하는 방법으로써, root state에서 시작하여 self-play로 simulation을 통해 다양한 experiences를 생성하고 이를 이용하여 Model-Free RL 중 하나인 MC를 쓴 것이다. 즉 action value를 experiences에서 학습하고 좋은 action들만 선택하는 방법이다. 하지만 exploration을 고려하여 UCT algorithm을 사용하여 매 node에서[5] action을 선택할 때, exploration 또한 진행한다.

5) Bandit 문제와 동일하다.

4-1. Smooth UCT Search

#. imperfect information일 때 사용하는 방법이며 average strategy를 생성하여 상대방의 average behaviour 를 배우고 UCT를 수정하는 방법이다.

$A \sim \begin{cases} \text{UCT}(S), & \text{with probability } \eta \\ \pi_{avg}(\cdot\|S), & \text{with probability } 1-\eta \end{cases}$	$\pi_{avg}(a\|s) = \frac{N(s,a)}{N(s)}$

a. 주로 Poker에서 사용하는 방법이다.

5. Conclusion

Program	Input features	Value Fn	RL	Training	Search
Chess *Meep*	Binary *Pieces, pawns, ...*	Linear	TreeStrap	Self-Play / Expert	$\alpha\beta$
Checkers *Chinook*	Binary *Pieces, ...*	Linear	TD leaf	Self-Play	$\alpha\beta$
Othello *Logistello*	Binary *Disc configs*	Linear	MC	Self-Play	$\alpha\beta$
Backgammon *TD Gammon*	Binary *Num checkers*	Neural network	TD(λ)	Self-Play	$\alpha\beta$ / MC
Go *MoGo*	Binary *Stone patterns*	Linear	TD	Self-Play	MCTS
Scrabble *Maven*	Binary *Letters on rack*	Linear	MC	Self-Play	MC search
Limit Hold'em *SmooCT*	Binary *Card abstraction*	Linear	MCTS	Self-Play	-

저작자 : 서강대학교 머신러닝 연구실 서강현 (sdsdsf123@naver.com)